

# NONPARAMETRIC REGRESSION USING DEEP NEURAL NETWORKS WITH RELU ACTIVATION FUNCTION

Prof. Schmidt-Hieber (2020)

## Literatur

Schmidt-Hieber, Johannes (Aug. 2020). “Nonparametric regression using deep neural networks with ReLU activation function”. In: *Annals of Statistics* 48.4, S. 1875–1897. ISSN: 0090-5364. DOI: 10.1214/19-aos1875. URL: <http://dx.doi.org/10.1214/19-AOS1875>.

## 1 Modell

Beobachte  $n$  i.i.d. Datenpunkte aus dem nichtparametrisches multivariaten Regressionsmodell

$$Y_i = f_0(\mathbf{X}_i) + \varepsilon_i \quad i = 1, \dots, n \quad (1)$$

- $Y_i \in \mathbb{R}$ ,  $\mathbf{X}_i \in [0, 1]^d$  zufällig
- $\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$  unabhängig von den  $(\mathbf{X}_i)_i$

**Ziel:** Rekonstruktion der unbekannten Funktion  $f_0 : [0, 1]^d \rightarrow \mathbb{R}$  anhand der Daten  $(\mathbf{X}_i, Y_i)_i$ .

## 2 Notation

- Vektoren werden dick gedruckt  $\mathbf{X}_i$
- $\|\mathbf{x}\|_p = (\sum_i |x_i|^p)^{1/p}$
- $\|\mathbf{x}\|_\infty = \max_{i=1, \dots, d} |x_i|$
- $\|\mathbf{x}\|_0 = \sum_i \mathbf{1}(x_i \neq 0)$

## 3 Neuronale Netzwerke

- Rectified Linear Unit (ReLU) als *Aktivierungsfunktion*:

$$\sigma : \mathbb{R} \rightarrow \mathbb{R} \quad \sigma(x) := \max(0, x)$$

- Für  $\mathbf{v} \in \mathbb{R}^r$  *verschobene Aktivierungsfunktion*:

$$\sigma_{\mathbf{v}} : \mathbb{R}^r \rightarrow \mathbb{R}^r \quad \sigma_{\mathbf{v}}\left(\begin{pmatrix} y_1 \\ \vdots \\ y_r \end{pmatrix}\right) := \begin{pmatrix} \sigma(y_1 - v_1) \\ \vdots \\ \sigma(y_r - v_r) \end{pmatrix}$$

- Ein Tupel  $(L, \mathbf{p})$  mit einer *Tiefe*  $L \in \mathbb{N}_{>0}$  und *Breitenvektor*  $\mathbf{p} = (p_0, \dots, p_{L+1}) \in \mathbb{N}^{L+2}$  heißt *Netzwerk Architektur*.
- Eine Funktion  $f : \mathbb{R}^{p_0} \rightarrow \mathbb{R}^{p_{L+1}}$  heißt *Neuronales Netzwerk* mit Netzwerk Architektur  $(L, \mathbf{p})$ , wenn *Gewichtsmatrizen*  $W_i \in \mathbb{R}^{p_{i+1} \times p_i}$  ( $i = 0, \dots, L$ ) und *Verschiebungsvektoren*  $\mathbf{v}_i \in \mathbb{R}^{p_i}$  ( $i = 1, \dots, L$ ) existieren, sodass für  $f$  gilt

$$f(\mathbf{x}) := W_L \sigma_{v_L} W_L \sigma_{\mathbf{v}_{L-1}} \dots W_1 \sigma_{\mathbf{v}_1} W_0 \mathbf{x} \quad (2)$$

Die Gewichtsmatrizen  $W_i$  und Verschiebungsvektoren  $v_i$  heißen *Parameter* des Neuronalen Netzwerkes.

- $\mathcal{F}(L, \mathbf{p}) := \left\{ f \text{ von Gestalt (2)} : \max_{j=0, \dots, L} \|W_j\|_\infty \vee |\mathbf{v}_j|_\infty \leq 1 \right\}$
- $\mathcal{F}(L, \mathbf{p}, s, F) := \left\{ f \in \mathcal{F}(L, \mathbf{p}) : \sum_{j=0}^L \|W_j\|_0 + |v_j|_0 \leq s, \|f\|_\infty \leq F \right\}$

Im Folgende bezeichne  $\hat{f}_n$  ein Schätzer für die Regressionsfunktion  $f_0$ , welcher stets eine Funktion aus der Klasse  $\mathcal{F}(L, \mathbf{p}, s, F)$  liefert

- $\Delta_n(\hat{f}_n, f_0) := \mathbb{E}_{f_0} \left[ \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{f}_n(\mathbf{X}_i))^2 - \inf_{f \in \mathcal{F}(L, \mathbf{p}, s, F)} \frac{1}{n} \sum_{i=1}^n (Y_i - f(\mathbf{X}_i))^2 \right]$
- $\hat{f}_n^{\text{ERM}}$  mit  $\Delta_n(\hat{f}_n^{\text{ERM}}, f_0) = 0$  heißt *Empirical Risk Minimizer*

- *Prediction error*

$$R(\hat{f}_n, f_0) = \mathbb{E}_{f_0} [(\hat{f}_n(\mathbf{X}) - f_0(\mathbf{X}))^2]$$

mit  $\mathbf{X} \stackrel{D}{=} \mathbf{X}_i$  unabhängig von den Daten  $(\mathbf{X}_i, Y_i)_i$

## 4 Annahmen

### 4.1 Klassische Nichtparametrische Statistik

- *Annahme:*  $f_0$  ist  $\beta$ -glatt
- *Minimax-Rate* für Prediction error  $R(\hat{f}_n, f_0)$ :  $n^{\frac{-2\beta}{2\beta+d}}$
- **Problem:**  $d$  kann sehr groß werden  $\implies$  *Curse of Dimensionality*

### 4.2 Annahmen von Prof. Schmidt-Hieber

- *Ziel:* Minimax-Rate unabhängig von der Input-Dimension  $d$
- Die Regressionsfunktion  $f_0$  lässt sich als Komposition von unterschiedlichen Funktionen schreiben

$$f_0 = g_q \circ g_{q-1} \circ \cdots \circ g_1 \circ g_0$$

mit  $g_i : [a_i, b_i]^{d_i} \rightarrow [a_{i+1}, b_{i+1}]^{d_{i+1}}$ .

Schreibe  $g_i = (g_{ij})_{j=1, \dots, d_{i+1}}^T$  mit Komponenten  $g_{ij}$ . Es bezeichne  $t_i$  die kleinste Zahl, sodass alle  $g_{ij}$  von nicht mehr als  $t_i$  Variablen abhängen.

- **$\beta$ -Hölder Funktionen** (mit Radius  $K$ )

$$\mathcal{C}_r^\beta(D, K) = \left\{ f : D \subseteq \mathbb{R}^r \rightarrow \mathbb{R} : \sum_{\alpha: |\alpha| < \beta} \|\partial^\alpha f\|_\infty + \sum_{\alpha: |\alpha| = \lfloor \beta \rfloor} \sup_{\substack{\mathbf{x}, \mathbf{y} \in D \\ \mathbf{x} \neq \mathbf{y}}} \frac{|\partial^\alpha f(\mathbf{x}) - \partial^\alpha f(\mathbf{y})|}{|\mathbf{x} - \mathbf{y}|_\infty^{\beta - \lfloor \beta \rfloor}} \leq K \right\}$$

- Definiere

$$\mathcal{G}(q, \mathbf{d}, \mathbf{t}, \beta, K) := \left\{ f = g_q \circ \cdots \circ g_0 : g_i = (g_{ij})_j : [a_i, b_i]^{d_i} \rightarrow [a_{i+1}, b_{i+1}]^{d_{i+1}} \right. \\ \left. \text{mit } g_{ij} \in \mathcal{C}_{t_i}^{\beta_i}([a_i, b_i]^{t_i}, K), \text{ für } |a_i|, |b_i| \leq K \right\}$$

mit  $\mathbf{d} := (d_0, \dots, d_{q+1}), \mathbf{t} := (t_0, \dots, t_q), \beta := (\beta_0, \dots, \beta_q)$

- **Effektive Glattheits-Indizes**

$$\beta_i^* := \beta_i \prod_{\ell=i+1}^q (\beta_\ell \wedge 1)$$

- **Rate**

$$\phi_n := \max_{i=0, \dots, q} n^{-\frac{2\beta_i^*}{2\beta_i^* + t_i}}$$

## 5 Hauptaussagen

**Theorem 1.** Betrachte das  $d$ -variate Regressionsmodell (1) mit unbekannter Regressionsfunktion  $f_0$  aus der Klasse  $\mathcal{G}(q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, K)$ . Es sei  $\hat{f}_n$  ein Schätzer mit Werten in  $\mathcal{F}(L, \mathbf{p}, s, F)$  sodass

- (i)  $F \geq \max(K, 1)$ ,
- (ii)  $\sum_{i=0}^q \log_2(4t_i \vee 4\beta_i) \log_2 n \leq L \lesssim n\phi_n$ ,
- (iii)  $n\phi_n \lesssim \min_{i=1, \dots, L} p_i$ ,
- (iv)  $s \asymp n\phi_n \log n$

Dann existieren Konstanten  $C, C'$ , die nur von  $q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, F$  abhängen, sodass

$$\begin{aligned} \Delta_n(\hat{f}_n, f_0) \leq C\phi_n L \log^2 n & \implies R(\hat{f}_n, f_0) \leq C'\phi_n L \log^2 n \\ \Delta_n(\hat{f}_n, f_0) \geq C'\phi_n L \log^2 n & \implies \frac{1}{C'}\Delta_n(\hat{f}_n, f_0) \leq R(\hat{f}_n, f_0) \leq C'\Delta_n(\hat{f}_n, f_0) \end{aligned}$$

**Korollar 1. (Obere Schranke)** Sei  $\hat{f}_n^{\text{ERM}} \in \arg \min_{f \in \mathcal{F}(L, \mathbf{p}, s, F)} \sum_{i=1}^n (Y_i - f(\mathbf{X}_i))^2$  ein empirischer Risiko-Minimierer. Dann existiert unter den Annahmen von Theorem 1 eine Konstante  $C'$ , die nur von  $q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, F$  abhängt, sodass

$$R(\hat{f}_n^{\text{ERM}}, f_0) \leq C'\phi_n L \log^2 n$$

**Theorem 3.** Betrachte das  $d$ -variate Regressionsmodell (1). Weiter habe die Verteilung der  $\mathbf{X}_i$  auf  $[0, 1]^d$  eine Dichte bezüglich des Lebesgue-Maßes, welche von oben und unten durch positive Konstanten beschränkt ist. Dann existiert für beliebiges nicht-negatives  $q$ , beliebigen Dimensionsvektoren  $\mathbf{d}$  und  $\mathbf{t}$  mit  $t_i \leq \min(d_0, \dots, d_{i-1})$  für alle  $i$ , beliebige Regularitätsvektoren  $\boldsymbol{\beta}$  und alle hinreichend große Konstanten  $K > 0$ , eine positive Konstante  $c$ , sodass

$$\inf_{\hat{f}_n} \sup_{f_0 \in \mathcal{G}(q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, K)} R(\hat{f}_n, f_0) \geq c\phi_n$$

wobei das erste Infimum über alle Schätzer  $\hat{f}_n$  gebildet wird.

**Theorem 2.** Betrachte das  $d$ -variate Regressionsmodell (1) mit unbekannter Regressionsfunktion  $f_0$  mit  $\|f_0\|_\infty \leq F$  für ein  $F \geq 1$ . Sei  $\hat{f}_n$  ein beliebiger Schätzer mit Werten in  $\mathcal{F}(L, \mathbf{p}, s, F)$ . Dann existiert für jedes  $\varepsilon \in (0, 1]$  eine Konstante  $C_\varepsilon$ , die nur von  $\varepsilon$  abhängt, sodass mit

$$\tau_{\varepsilon, n} := C_\varepsilon F^2 \frac{(s+1) \log(n(s+1)^L p_0 p_{L+1})}{n}$$

gilt

$$(1 - \varepsilon)^2 \Delta_n(\hat{f}_n, f_0) - \tau_{\varepsilon, n} \leq R(\hat{f}_n, f_0) \leq (1 + \varepsilon^2) \left( \inf_{f \in \mathcal{F}(L, \mathbf{p}, s, F)} \|f - f_0\|_\infty^2 + \Delta_n(\hat{f}_n, f_0) \right) + \tau_{\varepsilon, n}$$